


Dataset:

LendingClub

Cosa convince davvero un ente ad erogare un prestito?
Non è quello che pensi.

LendingClub

- P2P lending
- Prestiti online
- Rischio diversificato



Che dati abbiamo sui clienti ?



9.578 osservazioni, ciascuna rappresenta un prestito triennale **erogato nel periodo compreso tra maggio 2007 e febbraio 2010.**

- **ID cliente**
- **Profilo creditizio:** punteggio, ritardi, richieste, record negativi
- **Debiti:** quota reddito usata, saldo, utilizzo, pagamenti mancati
- **Prestito:** motivo, tasso, rata
- **Reddito annuale**




Analisi dei Dati

Distribuzione dei **Fico Score**: la maggior parte dei clienti ha un profilo creditizio buono o medio-buono, pochi casi estremi



Nella distribuzione degli Scopi del Prestito prevalgono debt consolidation e credit card, che rappresentano la maggior parte dei prestiti


Analisi dei Dati





$$DTI = (Debiti mensili / Reddito mensile) \times 100$$

Il DTI mostra una **distribuzione equilibrata** e stabile.
Non emergono forti sbilanciamenti verso valori alti o bassi.
Gli outlier non influenzano l'andamento generale.

La distribuzione della variabile **Interest Rate** non era ben distribuita.
Rendendo impossibile qualsiasi analisi affidabile.



Come varia il Tasso di Interesse per la categoria Fico Score?





Perchè alcuni clienti con Fico Score ottimo hanno tassi di interesse alti?

- $R^2 = 0.521$
- **Adjusted $R^2 = 0.643$**

una quota della variabilità del tasso rimane non spiegata,
suggerendo l'intervento di fattori esterni

non osservabili nel dataset (condizioni di mercato, politiche interne o caratteristiche contrattuali)

Esiste una relazione tra Fico Score e utilizzo del credito?




L'utilizzo del credito è una delle componenti del punteggio Fico Score. I risultati mostrano una correlazione negativa tra Fico Score e utilizzo del credito.

Quanto posso sapere dell'intensità di utilizzo del credito conoscendo solo il punteggio fico_score?"

- **$R^2 = 0.294$**


Che ruolo ha la DTI ?

Correlazione: DTI vs tutte le altre variabili numeriche




La DTI è moderatamente correlata con alcune variabili finanziarie (uso del credito, tasso di interesse), ma debole con molte altre, indicando una dimensione informativa propria.

dti per categoria fico




All'aumentare della qualità FICO, la DTI tende a diminuire, ma con forte sovrapposizione tra le categorie.

Boxplot DTI



I prestiti non ripagati mostrano DTI mediamente più alte, senza una separazione netta tra i gruppi.

Può il motivo di un prestito influire sul rischio?



Alcune categorie mostrano tassi di non rimborso più elevati, pur rappresentando una quota ridotta del totale.
Altre categorie più diffuse hanno tassi più contenuti.

Però questa differenza tra gli scopi del prestito è reale
o potrebbe essere dovuta al caso?

H0: La variabile purpose è indipendente dalla variabile not fully paid

H1: Esiste un'associazione tra purpose e not fully paid


Rifiutiamo l'ipotesi nulla: esiste un'associazione statisticamente significativa tra purpose e default.

p-value $\ll$ 0.05 (test χ^2)

È possibile prevedere se una richiesta di prestito verrà accettata o rifiutata basandosi solo sui dati finanziari del cliente?

Target: **credit_policy**

Analisi Esplorativa: Relazione tra Variabili e Approvazione




Applichiamo un approccio di Reverse Engineering per decostruire il processo di ammissibilità della piattaforma Lending Club.

Modello Predittivo


Logistic Regression

- **Lasso(L1)**
- **AUC: 92%**
- **Recall: 82%**






Validazione e Robustezza del Modello

Bootstrapping



Il paradosso del Bias



Predizione del Modello

Sto analizzando 3 casi casuali estratti dal database

CLIENTE ID #973
Dati Chiave: FICO 687 | Inquiries: 3 | Reddito Log: 10.67



RESPINTO (: 77.6%)
ternità STORICA: APPROVATO
RISULTATO: ERRORE. Il modello e la banca non sono d'accordo.

CLIENTE ID #89
Dati Chiave: FICO 737 | Inquiries: 0 | Reddito Log: 11.47



APPROVATO (: 98.6%)
ternità STORICA: APPROVATO
RISULTATO: CORRETTO! Il modello ha indovinato.

CLIENTE ID #8784
Dati Chiave: FICO 652 | Inquiries: 3 | Reddito Log: 10.59

RESPINTO (: 91.3%)
ternità STORICA: RESPINTO
RISULTATO: CORRETTO! Il modello ha indovinato.




Esistono gruppi naturali di clienti ?




Gruppo 0: Clienti **PRIME** a basso Rischio

Gruppo 1: Clienti **SUBPRIME** ad alto rischio

Visualizzazione dei due gruppi e relativo rischio



- Separazione prevalente lungo **prima componente principale**
- Presente zona di **sovrapposizione tra i gruppi**
- Indica profili **eterogenei**, non separabili in modo netto



Cluster più fragile → default più alto
Cluster più solido → default più basso

Possiamo predire il default?

Ricodiamoci però il contesto storico

THE WALL STREET JOURNAL.

DOW JONES
A NEW YORK COMPANY
TUESDAY, SEPTEMBER 30, 2008 - VOL. CCLII NO. 77
★★★★ \$2.00

Bailout Plan Rejected, Markets Plunge, Forcing New Scramble to Solve Crisis

BY SARAH LUECK,
DAMIAN PALETTA
AND GREG HITT

WASHINGTON—The House of Representatives defeated the White House's historic \$700 billion financial-rescue package—a stunning turn of events that sent the stock market into a tailspin and added to concerns that the U.S. faces a prolonged recession if the legislation isn't revived.

The Dow Jones Industrial Average sustained its biggest point drop in history and its biggest closing decline since the day the markets re-opened after the Sept. 11, 2001, terrorist attacks. The Dow, which had opened sharply lower on fears of more possible bank failures, finished the day down 7%, with a 777.68 point drop to 10365.45. Losses to shares on the broader Dow Jones Wilshire 5000 index amounted, on paper, to \$1.2 trillion—eclipsing the size of the proposed bailout package. The Nasdaq Stock Market finished down 9.1%.

The widely watched VIX index, a measure of market volatility often called “the fear index,” closed at its highest levels in its 28-year history. In early trading




Problemi:

- Nessun dato chiaro sui lay offs nel periodo analizzato.
- Poca trasparenza sulle fragilità del sistema finanziario.
- Molti indicatori economici non disponibili o incompleti.

Useremo 3 modelli


Logistic Regression



Il trade-off :

- Alta Recall (63.6%) ma bassa Precision (24.2%)
- È preferibile nel credit risk: meglio prudenti che esposti,

Confronto metriche




I modelli hanno risultati discreti a primo impatto

Possono essere utili in questo contesto ?


Profitto

Ciente che ripaga → il lender guadagna dagli interessi $\approx (\text{rata} \times 36) \times \text{tasso di interesse}$
Ciente in default → il lender perde il capitale $\approx \text{capitale non recuperato}$

Profitto totale del modello = $TN \times \text{Profitto} - FN \times \text{Perdita}$



E invece sui due cluster separati ?



Impatto economico per cluster

Clienti a basso rischio → profitto in entrambi gli scenari

Clienti ad alto rischio → perdita senza modello

Il modello **riduce drasticamente le perdite**

Separare i cluster migliora il risultato complessivo

Conclusioni

IL REVERSE ENGINEERING

Conferma dei Driver: Fico Score ed il Numero di Richieste sono i **pilastri decisionali**.

Regole Svelate: Identificata la distinzione tra **requisiti di accesso** e **indicatori di rischio comportamentali**.

LA SEGMENTAZIONE

Identificati tramite **Clustering** due gruppi netti.

Asimmetria del Profitto: Il Cluster "**Rischioso**" erode quasi tutto il margine generato dal Cluster "**Solido**".

Implicazione: Necessità di politiche di credito differenziate per segmento.

L'IMPATTO ECONOMICO

Nonostante l'imprevedibilità degli **eventi esterni**, il modello genera valore.

Il guadagno reale: L'integrazione tra Modello e Clustering trasforma una perdita potenziale in un **Profitto Netto**.

Decision Support: Il ML non elimina il rischio, ma lo rende **calcolabile e gestibile**.

Grazie per l'attenzione



Q&A